

Trabajo Práctico Final: Proyecto de Machine Learning

Asignatura: Aprendizaje Automático, 2026, Q1

Fecha de entrega: 24/06/2026 y fecha del final

Objetivo

El objetivo del trabajo final es desarrollar un proyecto completo de Machine Learning a partir de un dataset elegido por el grupo.

El foco no estará en obtener la mejor métrica posible sobre un dataset, sino en construir una solución razonada para un problema real o verosímil.

Entrega 1: (24/06/2026)

Cada grupo deberá entregar:

1. Presentación oral del contenido de los apartados 1 y 2.
2. Link o referencia al dataset utilizado.

Entrega 2: fecha del final (24h antes de la fecha elegida)

Cada grupo deberá entregar:

1. Presentación técnica del proyecto (contenido de los apartados 3 y 4) *de 10 minutos*.
2. Presentación no técnica del proyecto (apartado 5) *de 5 minutos*
3. Notebook reproducible.
4. Presentación oral el día del final de ambas presentaciones.

1. Elección del dataset, contexto de uso y formulación del problema

Cada grupo deberá elegir un dataset propio o público, por ejemplo de Kaggle, UCI, Hugging Face, datos gubernamentales u otra fuente válida (incluidos datos que tenga el estudiante para un proyecto personal).

No es suficiente con elegir un dataset “interesante”. El grupo deberá construir una situación realista alrededor del dataset. Es decir, el dataset debe ser útil para solucionar un problema real. Por eso, en la primera presentación del dataset, cada grupo deberá responder (aunque sea de manera ficticia) :

¿Qué problema concreto se va a resolver utilizando este dataset?, ¿Qué decisión se quiere mejorar?, ¿Quién usaría el modelo (institución, empresa etc)?, ¿Qué alternativa existe sin Machine Learning?

Ejemplo:

No sería suficiente decir: “Usamos un dataset de XXX para predecir si un cliente se va.”

Sería mejor decir: “Somos el equipo de datos de una empresa de telecomunicaciones. Queremos identificar clientes con alta probabilidad de abandonar el servicio para priorizar acciones de retención. El modelo no decide automáticamente, sino que ayuda al equipo comercial a ordenar casos según riesgo.”

2. Comprensión y justificación de los datos

El grupo deberá analizar si el dataset sirve para el problema planteado.

Deben discutir brevemente qué variables están contenidas, por qué son adecuados los datos para el contexto propuesto, si el dataset representa razonablemente el escenario donde se usaría el modelo...

La idea no es hacer gráficos por hacer gráficos, sino usar el análisis de datos para tomar decisiones.

3. Pipeline de trabajo

El grupo deberá construir un pipeline completo y justificado.

El trabajo debe incluir:

- análisis exploratorio de datos;
- preparación y limpieza;
- separación de datos para entrenamiento y evaluación;
- definición de un baseline;
- entrenamiento de uno o más modelos;
- evaluación con métricas adecuadas;
- análisis de errores;
- interpretación de resultados;
- discusión sobre uso real, riesgos y monitoreo.

Cada decisión importante debe estar justificada.

No se evaluará positivamente usar modelos complejos si no está claro por qué son necesarios.

4. Uso real, riesgos y monitoreo

Finalmente, el grupo deberá explicar cómo sería usar el modelo fuera del notebook.

Deben discutir:

- cómo llegarían nuevos datos;
- quién consumiría la predicción;
- qué habría que monitorear;
- qué señales indicarían que el modelo se está degradando;
- cuándo habría que reentrenarlo;
- qué riesgos éticos, sociales, legales o prácticos podrían aparecer.

La pregunta clave es:

¿Qué podría salir mal si este modelo se usa en una situación real?

5. Interpretación y comunicación (documento independiente)

De forma independiente al resto de la presentación. El grupo deberá traducir los resultados técnicos del “pipeline elegido” al lenguaje de decisión, como si fuese una presentación para un cliente (no técnico)

Deben responder: ¿Qué aprendimos del problema? ¿Qué variables parecen relevantes? ¿Cómo funciona nuestro modelo? ¿es fiable? ¿Qué limitaciones habría que comunicar? ¿Qué no debería hacerse con este modelo?

El objetivo es que una persona no técnica pueda entender para qué sirve el modelo, cuándo falla y cómo debería usarse.